

数工

データの分析



・ 度数分布表 … データのちらばりをまとめた表

階級 … 度数分布において区切られた区間

階級の幅 … 区間の幅

度数 … 各階級に含まれる値の個数

階級値 … 各階級のまん中の値

次のデータは、東京の2018年4月の日ごとの最高気温である。

| | | | | | | | | | |
|------|------|------|------|------|------|------|------|------|------|
| 21.9 | 24.5 | 23.4 | 26.2 | 15.3 | 22.4 | 21.8 | 16.8 | 19.9 | 19.1 |
| 21.9 | 25.9 | 20.9 | 18.8 | 22.1 | 20.0 | 15.0 | 16.0 | 22.2 | 26.4 |
| 26.0 | 28.3 | 18.7 | 21.3 | 22.5 | 25.0 | 22.0 | 26.1 | 25.6 | 25.7 |

(気象庁ホームページより作成、単位は°C)

最高気温の度数分布表

| 階級 (°C) | 度数 (日) |
|-------------|--------|
| 15 以上 18 未満 | 4 |
| 18 ~ 21 | 6 |
| 21 ~ 24 | 10 |
| 24 ~ 27 | 9 |
| 27 ~ 30 | 1 |
| 計 | 30 |

練習
1

前ページの度数分布表について、次の問い合わせよ。

- (1) 度数が9である階級の階級値を求めよ。
- (2) 最高気温が21°C以上の日は何日あるか。
- (3) 最高気温が低い方から数えて12番目の日が含まれる階級をいえ。

(1) 度数が9の階級は24°C以上27°C未満なので

$$\frac{24 + 27}{2} = 25.5$$

25.5 °C

(2) 最高気温が21°C以上の日は

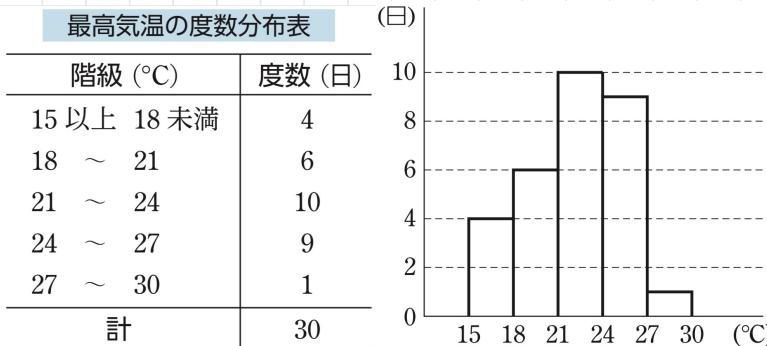
$$10 + 9 + 1 = 20$$

20日

(3) 階級の低い順から度数を数え、12に達するのは

21°C以上24°C未満

ヒストグラム … 度数分布表を柱状にしたもの



練習 2 次のデータは、ある高校の1年生女子20人の、ハンドボール投げの記録である。

| | | | | | | | | | |
|----|----|----|----|----|----|----|----|----|----|
| 16 | 13 | 14 | 13 | 14 | 11 | 14 | 17 | 16 | 15 |
| 18 | 16 | 17 | 15 | 17 | 16 | 21 | 16 | 20 | 19 |

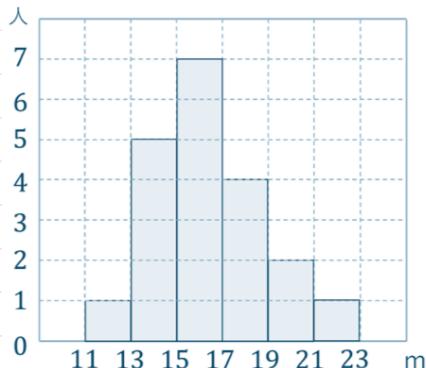
(単位はm)

- (1) 11m以上13m未満を階級の1つとして、どの階級の幅も2mである度数分布表を作れ。
- (2) (1)で作った度数分布表をもとにして、ヒストグラムをかけ。

(1)

| 階級(m) 以上 ~ 未満 | 度数 |
|------------------|-----------|
| 11 ~ 13 | 1 |
| 13 ~ 15 | 5 |
| 15 ~ 17 | 7 |
| 17 ~ 19 | 4 |
| 19 ~ 21 | 2 |
| 21 ~ 23 | 1 |
| 計 | 20 |

(2)



平均値

変量 x のデータの値が x_1, x_2, \dots, x_n であるとき、このデータ

の平均値 \bar{x} は
$$\bar{x} = \frac{1}{n}(x_1 + x_2 + \dots + x_n)$$

練習
3

次のデータは、ある生徒のある1週間における1日あたりの睡眠時間
である。このデータの平均値を求めよ。

400, 410, 420, 390, 430, 450, 440 (分)

$$\frac{400 + 410 + 420 + 390 + 430 + 450 + 440}{7} = 420$$

420 分

- ・ **最頻値 (モード)** … データにおいて最も個数が多い値
度数分布表においては度数の最も大きい階級の階級値を用いる。

練習
4

168 ページの度数分布表において、最頻値を求めよ。

最高気温の度数分布表

| 階級 (°C) | 度数 (日) |
|-------------|--------|
| 15 以上 18 未満 | 4 |
| 18 ~ 21 | 6 |
| 21 ~ 24 | 10 |
| 24 ~ 27 | 9 |
| 27 ~ 30 | 1 |
| 計 | 30 |

左の度数分布表において度数の最も大きい値の階級は

21°C 以上 24°C 未満 であるので

求める最頻値はこの階級の階級値

$$\frac{21+24}{2} = 22.5$$

22.5 °C

- ・ 中央値(メジアン) … データを値の大きさ順に並べたとき中央の位置にある値
データの大きさが偶数のときは中央2つの値の平均値とする。

練習
5

次のデータは、8人の生徒の右手の握力を測った結果である。その中
央値を求めよ。

38, 56, 43, 41, 35, 49, 51, 31 (kg)

データを値の大きさ順に並べると

56, 51, 49, 43, 41, 38, 35, 31

~~56, 51, 49, 43, 41, 38, 35, 31~~

↳ この平均値が中央値

$$\frac{43 + 41}{2} = 42$$

42 kg

範囲 … データのちらばりの度合いを表す値

範囲が大きいほどデータのちらばりの度合いが大きい

例 4 データの範囲

次のデータは、ある年のA市における月ごとの降水日数である。

7, 4, 9, 7, 10, 13, 14, 7, 4, 12, 13, 5 (日)

このデータの範囲は $14 - 4 = 10$ (日) 終

練習 6

次のデータは、例 4と同じ年のB市における月ごとの降水日数である。

このデータの範囲を求めよ。また、データの散らばりの度合いが大きいのはA市、B市のどちらと考えられるか。得られたデータの範囲によって比較せよ。

19, 16, 12, 11, 6, 8, 21, 13, 10, 14, 18, 22 (日)

このデータの範囲は

$$26 - 6 = 16 \text{ (日)}$$

A市の範囲が10日にに対してB市の範囲は16日なのでB市の方がデータのちらばりの度合いが大きい

- 四分位数 … データを大きさの順に並べたとき、データを4等分する位置にある値
小さい方から第1四分位数 Q_1 、第2四分位数 Q_2 、第3四分位数 Q_3

Q_1 … 下位のデータの中央値

データの大きさが 9 のとき

Q_2 … データ全体の中央値

2 6 8 9 13 16 19 21 29

Q_3 … 上位のデータの中央値

$$Q_1 = 7 \quad Q_2 = 13 \quad Q_3 = 20$$

データの大きさが 8 のとき

2 6 8 9 13 16 19 21

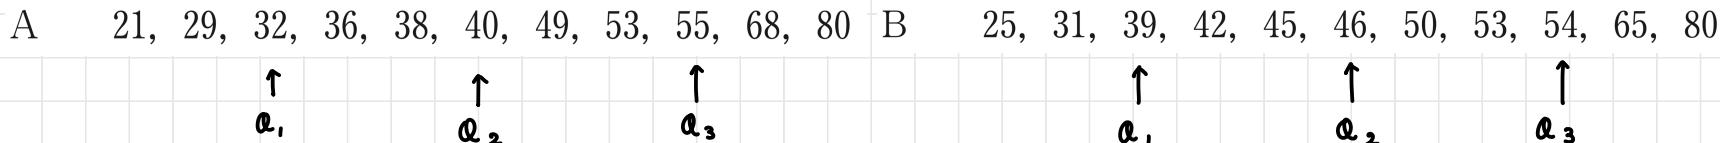
$$Q_1 = 7 \quad Q_2 = 11 \quad Q_3 = 17.5$$

- 四分位範囲 … (第3四分位数 Q_3 - 第1四分位数 Q_1) の値
- 四分位偏差 … 四分位範囲を 2 で割った値

練習 7

次のデータ A, B のそれぞれについて、四分位範囲を求めよ。また、データの散らばりの度合いが大きいのは A, B のどちらと考えられるか。

得られた四分位範囲によって比較せよ。



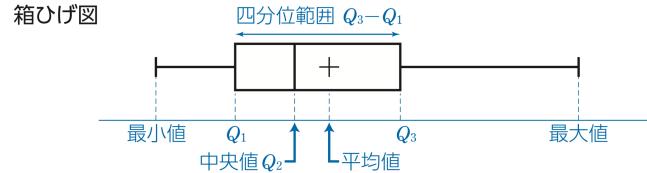
$$Q_3 - Q_1 = 55 - 32 = 23$$

$$Q_3 - Q_1 = 54 - 39 = 15$$

Aの方が四分位範囲が大きいのでデータのちらばりの度合いが大きいのはA

箱ひげ図 … データの分布を見るための図

最小値, 第1四分位数, 第2四分位数(中央値), 第3四分位数, 最大値を表現した図



箱ひげ図は複数のデータの分布を比較するときに便利な図である。

練習
8

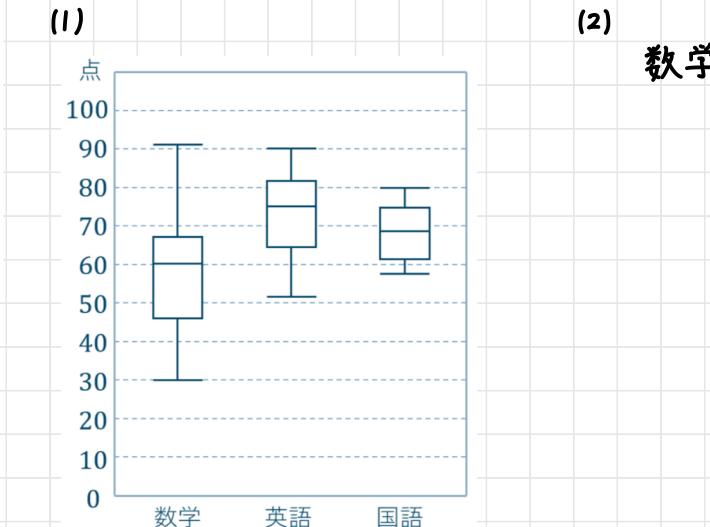
次のデータは、10人の生徒に100点満点の数学、英語、国語のテストを行った結果である。単位は点である。

数学 68, 35, 86, 63, 30, 91, 50, 63, 46, 58

英語 75, 65, 90, 78, 52, 88, 70, 75, 59, 82

国語 63, 60, 73, 75, 58, 79, 68, 70, 66, 80

- (1) これらのデータの箱ひげ図を並べてかけ。
- (2) データの散らばりの度合いが最も大きいのは、数学、英語、国語のうちどれと考えられるか。(1)で得られた箱ひげ図を用いて比較せよ。

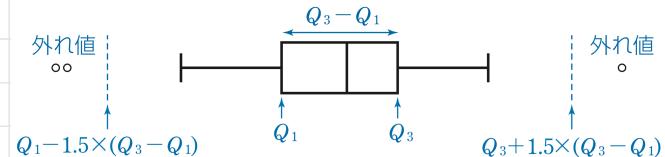


外れ値 … データの中の他の値から極端になれた値

(第1四分位数 - $1.5 \times$ 四分位範囲) 以下の値

(第3四分位数 + $1.5 \times$ 四分位範囲) 以上の値

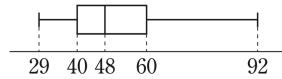
箱ひげ図への図示



練習
9

右の図はあるデータの箱ひげ図である。

このデータの最大値 92、最小値 29 は外れ値であるかを、四分位範囲を利用して調べよ。



四分位範囲は $60 - 40 = 20$

29が $Q_1 - 1.5 \times 20$ 以下であれば 29は外れ値である。

$40 - 1.5 \times 20 = 10$ なので 29は外れ値ではない

92が $Q_3 + 1.5 \times 20$ 以上であれば 92は外れ値である。

$60 + 1.5 \times 20 = 90$ なので 92は外れ値である。

よって

最大値 92は外れ値

最小値 29は外れ値ではない

- 偏差 … 変量 x のデータの値を x_1, x_2, \dots, x_n , 平均値を \bar{x} とするときの $x_1 - \bar{x}, x_2 - \bar{x}, \dots, x_n - \bar{x}$ のこと
- 分散 … 偏差の2乗の平均値, s^2 で表す。
- 標準偏差 … 分散の正の平方根, s で表す。

分散と標準偏差

変量 x のデータの値が x_1, x_2, \dots, x_n で, その平均値が \bar{x} のとき

$$\text{分散} \quad s^2 = \frac{1}{n} \{(x_1 - \bar{x})^2 + (x_2 - \bar{x})^2 + \dots + (x_n - \bar{x})^2\}$$

$$\text{標準偏差} \quad s = \sqrt{\text{分散}}$$

練習
10

次のデータは, 10人の生徒に計算テストを行った結果である。このデータの分散, 標準偏差を求めよ。

6, 10, 7, 7, 5, 4, 9, 10, 5, 7 (点)

合計点は 70 点

平均点は 7 点

$$\text{分散 } s^2 = \frac{1}{10} \left\{ (6-7)^2 + (10-7)^2 + (7-7)^2 + (7-7)^2 + (5-7)^2 + (4-7)^2 + (9-7)^2 + (10-7)^2 + (5-7)^2 + (7-7)^2 \right\} = \frac{1}{10} \times 40 = 4$$

$$\text{標準偏差 } s = \sqrt{4} = 2$$

| | |
|------|---|
| 分散 | 4 |
| 標準偏差 | 2 |

分散の求め方(2)

$$(x \text{ のデータの分散}) = (x^2 \text{ のデータの平均値}) - (x \text{ のデータの平均値})^2$$

..... ①

練習
11

次のデータについて、分散、標準偏差を求めよ。

5, 3, 6, 8, 5, 8, 5, 4, 6, 5

合計 55 平均 5.5

x^2 の \bar{x} - \bar{x} 25, 9, 36, 64, 25, 64, 25, 16, 36, 25 合計 325 平均 32.5

$$\text{分散 } S^2 = (\text{ } x^2 \text{ の } \bar{x} - \text{ } \bar{x} \text{ の 平均値})^2 = 32.5 - (5.5)^2 = 32.5 - 30.25 = 2.25$$

$$\text{標準偏差 } S = \sqrt{2.25} = 1.5$$

分散 2.25

標準偏差 1.5

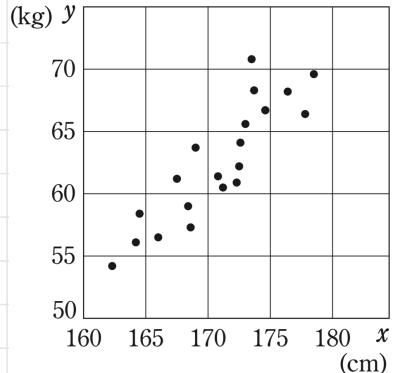
散布図 … 2つの変量からなるデータを点として平面上に図示したもの

(x の単位は cm, y の単位は kg)

| | ① | ② | ③ | ④ | ⑤ | ⑥ | ⑦ | ⑧ | ⑨ | ⑩ |
|-----|-------|-------|-------|-------|-------|-------|-------|-------|-------|-------|
| x | 168.4 | 164.5 | 171.2 | 173.0 | 162.3 | 170.8 | 172.5 | 164.2 | 169.0 | 168.6 |
| y | 59.0 | 58.4 | 60.5 | 65.6 | 54.2 | 61.4 | 62.2 | 56.1 | 63.7 | 57.3 |

| | ⑪ | ⑫ | ⑬ | ⑭ | ⑮ | ⑯ | ⑰ | ⑱ | ⑲ | ⑳ |
|-----|-------|-------|-------|-------|-------|-------|-------|-------|-------|-------|
| x | 172.6 | 166.0 | 173.7 | 176.4 | 178.5 | 167.5 | 177.8 | 174.6 | 172.3 | 173.5 |
| y | 64.1 | 56.5 | 68.3 | 68.2 | 69.6 | 61.2 | 66.4 | 66.7 | 60.9 | 70.8 |

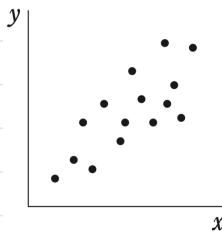
散布図にすると



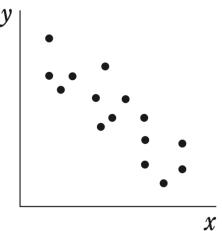
- 正の相関 … 2つの変量からなるデータにおいて、一方が増えると他方も増える傾向
- 負の相関 … 2つの変量からなるデータにおいて、一方が増えると他方が減る傾向

（どちらの傾向も見られなければ相関はない）

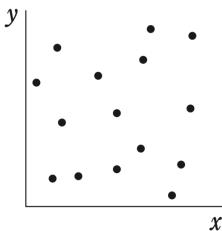
x と y の間に
正の相関がある



x と y の間に
負の相関がある



x と y の間に
相関がない



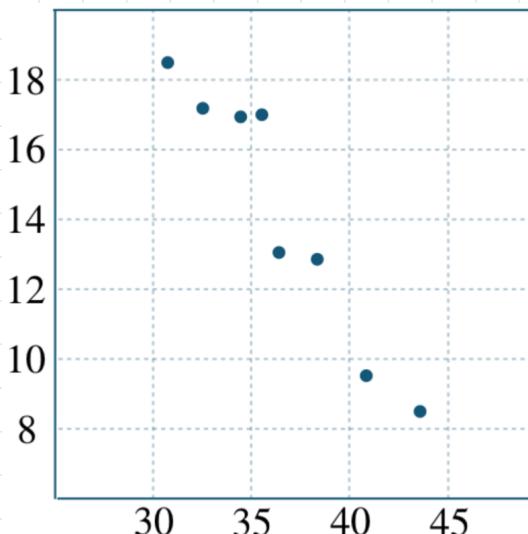
下の表は、各地点の緯度 x (度) と 2018 年 4 月の平均気温 $y(^{\circ}\text{C})$ を調べた結果である。

| 地点 | 札幌 | 青森 | 仙台 | 東京 | 長野 | 大阪 | 高知 | 鹿児島 |
|-----|------|------|------|------|------|------|------|------|
| x | 43.1 | 40.8 | 38.3 | 35.7 | 36.7 | 34.7 | 33.6 | 31.6 |
| y | 8.2 | 9.6 | 12.5 | 17.0 | 13.1 | 16.9 | 17.3 | 18.5 |

(気象庁ホームページより作成)

- (1) 2つの変量 x , y の散布図をかけ。
- (2) x と y の間には、正、負どちらの相関があると考えられるか。

(1)



(2) 負の相関がある。

- 相関係数 … X と Y の共分散を X の標準偏差と Y の標準偏差の積で割ったもの。 r で表す。

$$r = \frac{X \text{ と } Y \text{ の 共 分 散}}{(X \text{ の 標 準 偏 差}) \times (Y \text{ の 標 準 偏 差})}$$

ここで $|r|$ は $-1 \leq r \leq 1$ であり、正の相関が強いほど r は 1 に近づく

負の相関が強いほど r は -1 に近づく

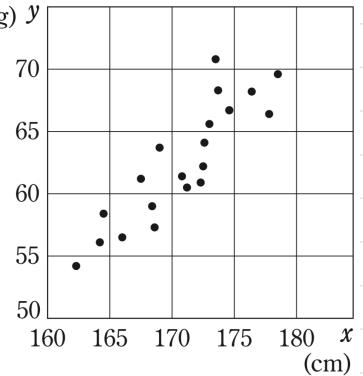
相関がないときは r は 0 に近い値となる。

- 共分散 … X と Y の偏差の積の平均 $\rightarrow \frac{1}{n} \left\{ (x_1 - \bar{x})(y_1 - \bar{y}) + (x_2 - \bar{x})(y_2 - \bar{y}) + \cdots + (x_n - \bar{x})(y_n - \bar{y}) \right\}$

(x の単位は cm, y の単位は kg) (kg) y

| | ① | ② | ③ | ④ | ⑤ | ⑥ | ⑦ | ⑧ | ⑨ | ⑩ |
|-----|-------|-------|-------|-------|-------|-------|-------|-------|-------|-------|
| x | 168.4 | 164.5 | 171.2 | 173.0 | 162.3 | 170.8 | 172.5 | 164.2 | 169.0 | 168.6 |
| y | 59.0 | 58.4 | 60.5 | 65.6 | 54.2 | 61.4 | 62.2 | 56.1 | 63.7 | 57.3 |

| | ⑪ | ⑫ | ⑬ | ⑭ | ⑮ | ⑯ | ⑰ | ⑱ | ⑲ | ⑳ |
|-----|-------|-------|-------|-------|-------|-------|-------|-------|-------|-------|
| x | 172.6 | 166.0 | 173.7 | 176.4 | 178.5 | 167.5 | 177.8 | 174.6 | 172.3 | 173.5 |
| y | 64.1 | 56.5 | 68.3 | 68.2 | 69.6 | 61.2 | 66.4 | 66.7 | 60.9 | 70.8 |



練習
13

185 ページのデータについて、 x の標準偏差は 4.40, y の標準偏差は 4.71, x と y の共分散は 18.22 である。これらの数値を用いて、 x と y の相関係数を計算せよ。ただし、小数第 3 位を四捨五入せよ。

$$r = \frac{\text{XとYの共分散}}{(\text{Xの標準偏差}) \times (\text{Yの標準偏差})} = \frac{18.22}{4.40 \times 4.71} = 0.88$$

0.88

以下の表は、6人の生徒に10点満点の2種類のテストA, Bを行った結果である。A, Bの得点の相関係数を求めよ。また、これらの間にはどのような相関があると考えられるか。

| | ① | ② | ③ | ④ | ⑤ | ⑥ |
|------|---|---|---|---|---|---|
| テストA | 5 | 7 | 5 | 4 | 3 | 6 |
| テストB | 4 | 1 | 3 | 5 | 9 | 2 |

(単位は点)

テストAのデータをX、テストBのデータをYとする。

$$\bar{x} = \frac{1}{6} \times (5 + 7 + 5 + 4 + 3 + 6) = 5, \quad \bar{y} = \frac{1}{6} \times (4 + 1 + 3 + 5 + 9 + 2) = 4$$

| X | Y | X - \bar{x} | Y - \bar{y} | (X - \bar{x})(Y - \bar{y}) | $(X - \bar{x})^2$ | $(Y - \bar{y})^2$ |
|---|---|---------------|---------------|----------------------------------|-------------------|-------------------|
| 5 | 4 | 0 | 0 | 0 | 0 | 0 |
| 7 | 1 | 2 | -3 | -6 | 4 | 9 |
| 5 | 3 | 0 | -1 | 0 | 0 | 1 |
| 4 | 5 | -1 | 1 | -1 | 1 | 1 |
| 3 | 9 | -2 | 5 | -10 | 4 | 25 |
| 6 | 2 | 1 | -2 | -2 | 1 | 4 |
| | | | | <u>-19</u> | <u>10</u> | <u>40</u> |

相関係数rは

$$r = \frac{-19}{\sqrt{10} \times \sqrt{40}} = -\frac{19}{20} = -0.95$$

r = -0.95より強い負の相関がある。